I. Рассмотреть зависимость $y = 1 + 3x_1 - 2x_2 + x_3 + e$, где случайная величина e распределена по нормальному закону $N(0,1)$. Сгенерировать 200 различных замеров вектора факторов (x_{1k}, x_{2k}, x_{3k}) и вычислить соответствующие им значения отклика y_k. По сгенерированным данным построить множественную линейную регрессию.

1. Значения факторов x_{1k}, x_{2k}, x_{3k} и ошибки e_k сгенерированы независимо из $N(0,1)$, $k = 1, \ldots, n$, $n = 200$. Отклик вычислен по формуле $y_k = 1 + 3x_{1k} - 2x_{2k} + x_{3k} + e_k$. Первые пять замеров:

k	x_{1k}	x_{2k}	x_{3k}	y_k	$\hat{y}_k$
1	0.305	−1.040	0.750	5.260	4.688
2	0.941	−1.951	−1.302	5.844	6.501
3	0.128	−0.316	−0.017	3.274	1.970
4	−0.853	0.879	0.778	−3.168	−2.655
5	0.066	1.127	0.468	−1.225	−0.656

2. Модель множественной линейной регрессии с $p = 3$ факторами:

$$y_k = \beta_0 + \beta_1 x_{1k} + \beta_2 x_{2k} + \beta_3 x_{3k} + e_k, \qquad k = 1, \ldots, n.$$

В матричной форме $X = (1\ x_1\ x_2\ x_3)$ — матрица размера 200×4, первый столбец которой состоит из единиц. МНК-оценки:

$$\hat{\beta} = (X^T X)^{-1} X^T y.$$

Стандартные ошибки оценок берутся из диагонали матрицы $\hat{V}(\hat{\beta}) = s_e^2 (X^T X)^{-1}$, где $s_e^2 = \frac{RSS}{n-p-1}$. Для проверки значимости каждого коэффициента используется $t = \hat{\beta}_j / SE(\hat{\beta}_j)$ с $n - p - 1 = 196$ степенями свободы.

3. Результаты:

Коэффициент	Истинное значение	$\hat{\beta}_j$	$SE(\hat{\beta}_j)$	t	p-значение
β_0	1	0.9629	0.0726	13.27	$4 \cdot 10^{-29}$
β_1	3	3.0368	0.0722	42.07	$5 \cdot 10^{-100}$
β_2	−2	−2.0076	0.0749	−26.80	$2 \cdot 10^{-67}$
β_3	1	0.9483	0.0776	12.22	$7 \cdot 10^{-26}$

Уравнение регрессии:

$$\hat{y} = 0.963 + 3.037\, x_1 - 2.008\, x_2 + 0.948\, x_3.$$

Все оценки отличаются от истинных значений меньше чем на две стандартные ошибки, то есть истинные коэффициенты попадают в 95%-доверительные интервалы $\hat{\beta}_j \pm 2\, SE(\hat{\beta}_j)$.

II. Вычислить сумму квадратов остатков (RSS), стандартную ошибку остатков (RSE) и корреляционное отношение η^2 (R^2). Сделать выводы о степени адекватности линейной модели.

1. Сумма квадратов остатков и общая сумма квадратов:

$$RSS = \sum_{k=1}^{n} (y_k - \hat{y}_k)^2 \approx 205.27, \qquad TSS = \sum_{k=1}^{n} (y_k - \bar{y})^2 \approx 2732.46.$$

2. Стандартная ошибка остатков:

$$RSE = \sqrt{\frac{RSS}{n-p-1}} = \sqrt{\frac{205.27}{196}} \approx 1.023.$$

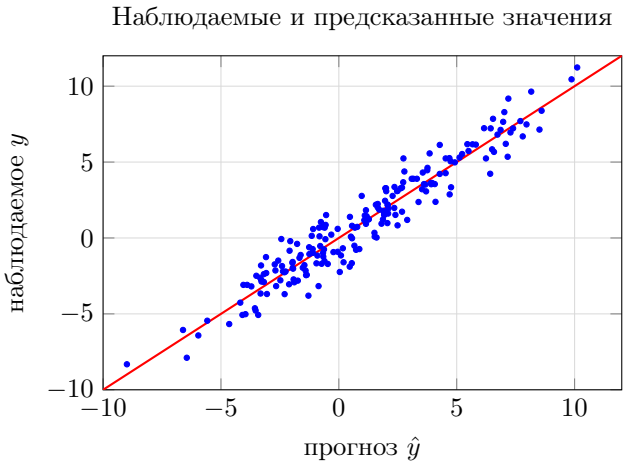
3. Корреляционное отношение:

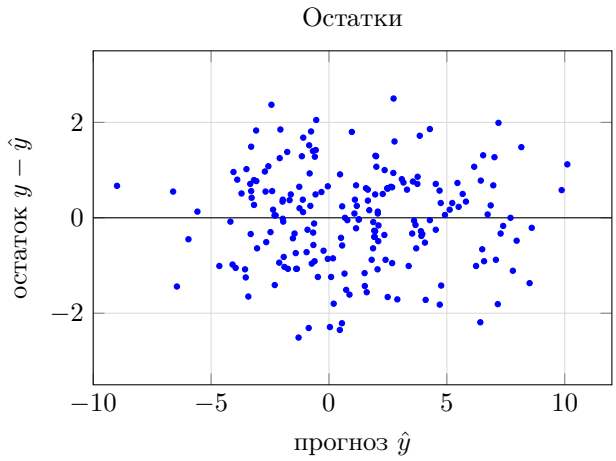
$$\eta^2 = R^2 = \frac{TSS - RSS}{TSS} = \frac{2732.46 - 205.27}{2732.46} \approx 0.925.$$

4. Проверим гипотезу $H_0 : \beta_1 = \beta_2 = \beta_3 = 0$ с помощью F-статистики:

$$F = \frac{(TSS - RSS)/p}{RSS/(n-p-1)} = \frac{(2732.46 - 205.27)/3}{205.27/196} \approx 804.3.$$

Критическое значение распределения Фишера $F_{0.95}(3, 196) \approx 2.65$, p-значение порядка 10^{-110}. Гипотеза H_0 отвергается: отклик связан с факторами.





Вывод: модель объясняет около 92.5% разброса отклика, F-критерий подтверждает наличие связи, все коэффициенты значимы и близки к истинным. $RSE \approx 1.02$ практически совпадает со стандартным отклонением ошибки $\sigma = 1$, то есть оставшийся разброс объясняется только случайной ошибкой e. Остатки расположены вокруг нуля без видимой закономерности. Линейная модель адекватна.

III. На сайте http://www.pogodaiklimat.ru/file.htm найти данные о среднегодовых температурах за период наблюдений. Построить полиномиальные линейные регрессии температуры от времени. Реализовать процедуру прямого отбора при выборе степени полинома.

1. Взяты среднегодовые температуры Тюмени за последние 40 лет наблюдений (1986–2025 гг.):

Год	1986	1987	1988	1989	1990	1991	1992	1993	1994	1995
T, °C	0.6	1.2	2.7	2.5	2.9	2.9	1.6	1.2	1.5	4.1
Год	1996	1997	1998	1999	2000	2001	2002	2003	2004	2005
T, °C	1.3	2.0	1.4	2.0	2.4	1.6	2.1	3.3	2.7	3.1
Год	2006	2007	2008	2009	2010	2011	2012	2013	2014	2015
T, °C	1.8	3.3	3.7	2.0	1.4	2.0	2.7	3.0	1.7	3.1
Год	2016	2017	2018	2019	2020	2021	2022	2023	2024	2025
T, °C	2.8	2.6	1.6	2.8	4.7	2.9	2.9	4.3	3.6	4.4

2. Полиномиальная регрессия степени p:

$$T = \beta_0 + \beta_1 z + \beta_2 z^2 + \cdots + \beta_p z^p + e,$$

сводится к множественной линейной регрессии введением факторов $X_j = z^j$, $j = 1, \ldots, p$. Здесь $z_k = (t_k - \bar{t})/s_t$ — год, приведённый к нулевому среднему и единичному разбросу ($\bar{t} = 2005.5$, $s_t \approx 11.54$). Без этого значения t_k^p при $t_k \approx 2000$ отличаются на много порядков и матрица $X^T X$ получается плохо обусловленной.

3. Прямой отбор: начинаем с нулевой модели $T = \beta_0$ и на каждом шаге добавляем следующую степень z^p. Новая степень остаётся в модели, если её коэффициент значим (p-значение t-статистики меньше 0.05). Как только добавленная степень оказывается незначимой, процедура останавливается. Характеристики моделей степеней от 1 до 6:

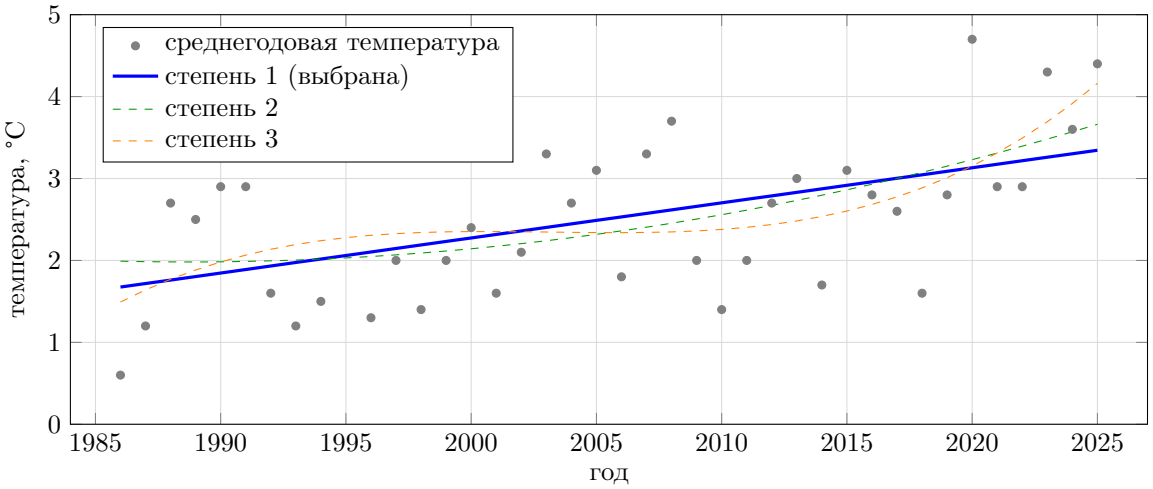
Степень p	RSS	RSE	R^2	t нового коэффициента	p-значение
1	26.897	0.841	0.267	3.72	0.001
2	25.967	0.838	0.292	1.15	0.257
3	24.042	0.817	0.345	1.70	0.098
4	24.017	0.828	0.345	0.19	0.851
5	22.922	0.821	0.375	1.27	0.211
6	20.181	0.782	0.450	−2.12	0.042

На первом шаге коэффициент при z значим ($p = 0.001$), на втором коэффициент при z^2 незначим ($p = 0.257$). Процедура останавливается, выбрана степень $p = 1$.

4. Выбранная модель:

$$\hat{T} = 2.510 + 0.494\, z = 2.510 + 0.0428\,(t - 2005.5),$$

то есть среднегодовая температура растёт примерно на 0.43 °C за 10 лет. Для неё $RSE \approx 0.84$ °C, $R^2 \approx 0.27$, $F \approx 13.8$ (p-значение 0.0006).



Вывод: R^2 растёт с каждой новой степенью (от 0.267 до 0.450), потому что полином большей степени всегда лучше подгоняется к тем же точкам. Однако уже вторая степень не даёт значимого улучшения, и прямой отбор выбирает линейную модель. У степени 6 p-значение формально меньше 0.05, но до неё процедура не доходит; при 40 точках полином шестой степени в основном подстраивается под случайные колебания отдельных лет. Линейная модель показывает значимый рост температуры, но объясняет только около 27% разброса: остальное приходится на колебания от года к году, которые трендом не описываются.